

SPEAKER NOTES PREMIUM - BLOQUE 1 (SLIDES 1-10)

SLIDE 1 – GO / NO GO

Tiempo: 30 segundos

Buenos días. Antes de empezar quiero haceros una pregunta. ¿Cuántos de vosotros habéis hecho alguna vez un viaje para practicar un deporte y al llegar os habéis encontrado que las condiciones no eran las esperadas? Este proyecto nace exactamente de esa frustración. Hoy os presentaré GO / NO GO, un sistema basado en Machine Learning para responder una pregunta muy sencilla: ¿merece la pena salir a navegar hoy?

NOTA: Pausa después de 'llegas a la playa' y sonríe al decir 'y no hay viento'.

SLIDE 2 – Terminology

Tiempo: 30 segundos

Este proyecto no trata únicamente sobre viento. Trata sobre incertidumbre y sobre cómo utilizar datos para reducir esa incertidumbre. Antes de entrar en la parte técnica repasaremos algunos conceptos clave.

SLIDE 3 – The Problem

Tiempo: 45 segundos

Imaginad que son las siete de la mañana. El coche está cargado. El neopreno preparado. Las velas listas. Llegáis al spot... y no hay viento. ¿Os ha pasado alguna vez algo parecido? Ese problema aparentemente simple tiene consecuencias reales: tiempo perdido, combustible y frustración. La pregunta es: ¿podemos utilizar Machine Learning para mejorar esa decisión?

SLIDE 4 – Project Objective

Tiempo: 45 segundos

El objetivo fue transformar datos en una decisión: GO o NO GO. Para ello necesitábamos identificar eventos de brisa marina, descubrir qué variables los explican y entrenar un modelo capaz de detectar esos patrones. Datos → Modelo → Decisión.

SLIDE 5 – Data Sources

Tiempo: 45 segundos

Utilicé tres fuentes de datos independientes. Entre todas superan los cuatro millones de registros históricos desde 2010 hasta 2025. Antes de entrenar modelos fue necesario construir un pipeline completo de limpieza, integración y transformación.

SLIDE 6 – The Datasets

Tiempo: 1 minuto

Buscaviento aporta las observaciones reales de viento. XEMA aporta información meteorológica como temperatura, presión e irradiancia solar. La boya oceanográfica aporta SST. La combinación de las tres fuentes permite describir el fenómeno desde distintos puntos de vista.

SLIDE 7 – Hypothesis

Tiempo: 1 minuto

Antes de aplicar Machine Learning formulé tres hipótesis físicas: más sol implica más brisa marina; un mayor contraste térmico tierra-mar favorece la circulación térmica; y una mayor amplitud térmica día-noche aumenta la probabilidad del fenómeno.

SLIDE 8 – Seasonal Pattern

Tiempo: 1 minuto

Los meses cálidos presentan más eventos de brisa marina. Este patrón es coherente con la teoría meteorológica: más energía solar implica mayor calentamiento terrestre y, por tanto, más circulación térmica.

SLIDE 9 – Long-Term Wind Stability

Tiempo: 45 segundos

Aunque existe variabilidad anual, observamos una notable estabilidad a largo plazo. Esto indica que el fenómeno tiene una señal consistente y no es simplemente ruido aleatorio.

SLIDE 10 – Hypothesis Validation

Tiempo: 1 minuto

Este es uno de los gráficos más importantes. A medida que aumenta el contraste térmico entre aire y mar, aumenta la probabilidad de brisa marina. Los datos están confirmando la teoría física y justifican pasar a la fase de Machine Learning.

SLIDE 12 – Season x Month

Tiempo: 45 segundos. Este gráfico permite entender la estacionalidad del fenómeno. No todos los meses se comportan igual. La información temporal aporta capacidad predictiva y justifica el uso de variables como mes, estación y día del año.

SPEAKER NOTES PREMIUM - BLOQUE 2 (SLIDES 11-20)

SLIDE 11 – Hypothesis Validation

Tiempo: 45 segundos. Validación de la hipótesis relacionada con el gradiente térmico día-noche. Cuanto mayor es la diferencia térmica entre el día y la noche, mayor es la probabilidad de aparición de brisa marina. Interpretación física: un mayor calentamiento diurno favorece una circulación térmica más intensa.

SPEAKER NOTES PREMIUM - BLOQUE 3

SLIDE 21 – Validation Analysis

F1 Test=0.518, AUC Test=0.714, F1 Validation=0.470, AUC Validation=0.701. El modelo mantiene estabilidad temporal y no muestra sobreajuste severo.

SLIDE 22 – Limitations

Actualmente el sistema debe considerarse principalmente un clasificador histórico. Varias variables utilizan información disponible el mismo día.

SLIDE 23 – Roadmap

Integración futura con Open-Meteo, GFS y variables disponibles antes de las 07:00 para construir una predicción operativa real.

SLIDE 24 – Final Conclusions

La brisa marina no es aleatoria. Existen patrones físicos identificables y Machine Learning puede capturarlos. El proyecto demuestra el potencial de un sistema GO / NO GO.

SLIDE 25 – Thank You

La mejor sesión no es la que ocurre. Es la que sabes que va a ocurrir. Muchas gracias por vuestra atención.

Pregunta Difícil: Accuracy vs Dummy

El Dummy siempre predice NO GO. Como el 69% de los días no tienen viento térmico, obtiene alta accuracy sin aprender nada. Mi modelo detecta el 61.6% de los días reales con viento térmico, que es lo que realmente importa.

Pregunta Difícil: Recall

El dataset está desbalanceado. Por eso Recall, F1 y ROC-AUC son métricas más relevantes que Accuracy.

Pregunta Difícil: ¿Es bueno el modelo?

Como clasificador histórico sí. Como sistema operativo todavía no. Necesita variables predictivas disponibles antes de las 07:00.

Chuleta Final

Problema: saber si habrá viento. Objetivo: GO/NO GO. Datos: 3 datasets y más de 4 millones de registros. Modelo: Random Forest. Recall=0.616. ROC-AUC=0.714. Conclusión: la brisa marina no es aleatoria.

SLIDE 13 – Temporal Split Strategy

Tiempo: 1 minuto. Entrenamiento 2010-2021, Test 2022-2023 y Validación 2024-2025. Esta separación temporal evita fugas de información y simula el comportamiento real que tendría el modelo en producción.

SLIDE 14 – Features Used

Tiempo: 1 minuto. Variables térmicas, meteorológicas y temporales. Punto clave: se eliminaron todas las variables de viento observado. El modelo debe inferir la presencia de viento únicamente a partir de las condiciones atmosféricas.

SLIDE 15 – Baseline Analysis

Tiempo: 1 minuto. El Dummy Classifier siempre predice la clase más frecuente. En este caso siempre dice NO GO. Resultado: $F1=0$ para los días con brisa marina. Cualquier mejora posterior representa aprendizaje real.

SLIDE 16 – Random Forest Architecture

Tiempo: 1 minuto. Se seleccionó Random Forest por robustez, interpretabilidad y capacidad para modelar relaciones no lineales. Configuración: 500 árboles, profundidad máxima 12 y balanceo de clases.

SLIDE 17 – Results Interpretation

Tiempo: 1 minuto. Accuracy 0.648, Precision 0.447, Recall 0.616, F1 0.518 y ROC-AUC 0.714. El mensaje clave es que el Recall es la métrica más importante porque el objetivo es detectar días navegables.

SLIDE 18 – Confusion Matrix

Tiempo: 1 minuto. Desde una perspectiva operativa es preferible una falsa alarma a perder un día excepcional de navegación. La matriz de confusión permite visualizar ese equilibrio entre errores.

SLIDE 19 – ROC Curve

Tiempo: 1 minuto. Un ROC-AUC de 0.714 indica que el modelo distingue razonablemente bien entre días con y sin brisa marina. El rendimiento es claramente superior al azar.

SLIDE 20 – Feature Importance

Tiempo: 1 minuto. La irradiancia solar, los gradientes térmicos y la SST aparecen como variables dominantes. El modelo aprende mecanismos meteorológicos coherentes y no patrones aleatorios.